POLITECHNIKA BIAŁOSTOCKA

WYDZIAŁ INFORMATYKI

DOKUMENTACJA PROJEKTOWA

TEMAT: Detekcja tekstu wygenerowanego AI

WYKONAWCY: Michał Dąbrowski
Dominik Zabielski

PROWADZĄCY: dr hab. inż. Sławomir Zieliński

BIAŁYSTOK, PAŹDZIERNIK 2026

Subject of diploma thesis:
Detection of AI-generated text

Summary

This document presents the project plan for detecting AI-generated text. It covers related work, consultations with an expert (dr hab. Piotr Hońko) and with a generative AI system, a brief requirements analysis, project scope, a preliminary schedule, and a GenAI usage statement. The minimum success criterion is classification accuracy of at least 51% on a chosen test set.

Spis treści

1 Opis zmian **4**

2 Tło projektu **5**

2.1 Przegląd podobnych rozwiązań 5

2.2 Stan wiedzy 5

2.3 Uwarunkowania komercyjne 6

2.4 Wyniki konsultacji z ekspertem 6

2.5 Wyniki konsultacji AI 6

2.6 Porównanie odpowiedzi eksperta i AI 7

3 Skrótowa analiza wymagań **9**

4 Zakres projektu i harmonogram **10**

4.1 Zakres 10

4.2 Proponowane zbiory danych 10

4.3 Harmonogram (diagram Gantta) 11

5 Szczegółowa specyfikacja projektu i opis wymagań **12**

5.1 Cel i kryterium sukcesu 12

5.2 Wejście / wyjście 12

5.3 Założenia 12

5.4 Ograniczenia 12

6 Opis wyników prac **13**

7 Oświadczenie wykorzystania narzędzi GenAI **14**

Bibliografia **15**

Spis rysunków **15**

1 Opis zmian

Wersja	Data	Opis zmian	Autorzy
1.0	20.10.2026	Pierwsza wersja dokumentacji: tło, konsultacje ekspert/AI, wymagania, zakres i harmonogram.	M. Dąbrowski, D. Zabielski

2 Tło projektu

2.1 Przegląd podobnych rozwiązań

Detekcja tekstu generowanego przez modele językowe (LLM) jest aktywnie rozwijanym obszarem. Istnieją zarówno narzędzia komercyjne, jak i metody badawcze:

- **GPTZero, Turnitin, Originality.ai** - systemy komercyjne stosowane m.in. w edukacji; opierają się na cechach stylometrycznych i modelach klasyfikacji.
- **DetectGPT / Fast-DetectGPT** - metody oparte na zaburzeniach prawdopodobieństwa (perturbation) tekstu względem modelu językowego.
- **Klasyfikatory nadzorowane** - modele typu RoBERTa/BERT trenowane na parach tekstów ludzkich i sztucznych (np. HC3, M4).
- **Watermarking** - oznaczanie wyjścia LLM na etapie generacji (np. schemat Kirchenbauer i in.); wymaga współpracy po stronie generatora.

W praktyce dokładność detektorów spada przy krótkich tekstach, parafrazie oraz tekstach wielojęzycznych. Dla języka polskiego liczba gotowych narzędzi i zbiorów jest wyraźnie mniejsza niż dla angielskiego.

2.2 Stan wiedzy

Problem sprowadza się zwykle do klasyfikacji binarnej: tekst ludzki vs tekst wygenerowany. Stosowane są dwa główne nurty:

1. **Podejścia statystyczne / stylometryczne** - entropia, perplexity, burstiness, rozkład długości zdań, częstości n-gramów. Działają bez dużego zbioru treningowego, ale bywają wrażliwe na domenę i długość tekstu.
2. **Uczenie maszynowe / głębokie** - klasyfikatory na embeddingach lub fine-tuning transformerów. Wymagają danych treningowych; przy małej liczbie przykładów łatwo o przeuczenie.

W literaturze podkreśla się, że metryki oparte na perplexity zawodzą przy bardzo krótkich próbkach (kilka zdań). Różnorodność generatorów (GPT, Llama, Gemini itd.) utrudnia generalizację jednego modelu detekcji.

2.3 Uwarunkowania komercyjne

Rynek detekcji AI jest związany głównie z edukacją, wydawnictwami i moderacją treści. Dostawcy komercyjni rzadko publikują pełne wyniki i ograniczenia modeli. Dla projektu akademickiego istotne są:

- dostępność otwartych zbiorów danych (Kaggle, Hugging Face),
- koszty API generatorów przy tworzeniu własnych próbek,
- brak gwarancji, że wynik detektora ma moc dowodową (ryzyko fałszywych oskarżeń).

2.4 Wyniki konsultacji z ekspertem

Konsultacje przeprowadzono z **dr. hab. Piotrem Hońko** (Wydział Informatyki PB). Poniżej pytania i odpowiedzi eksperta.

1. *Czy lepiej używać podejść statystycznych czy uczenia maszynowego?*
   Odpowiedź: Nie ma lepszego rozwiązania; dla małych zestawów danych podejście statystyczne może być lepsze.
2. *Czy teksty muszą być podobne tematycznie i czy w ogóle to jest możliwe?*
   Odpowiedź: Dla statystyki nie; dla ML tak.
3. *Jak podejść do problemu długości tekstu? Wiele metryk zawodzi na bardzo krótkich tekstach (np. 2-3 zdania).*
   Odpowiedź: Dobrać odpowiednie podejście.
4. *Czy warto nakładać minimalny limit długości tekstu w projekcie?*
   Odpowiedź: To zależy od podejścia - statystycznego albo ML.

2.5 Wyniki konsultacji AI

Te same pytania zadano modelowi językowemu (ChatGPT). Odpowiedzi AI:

1. *Podejścia statystyczne vs ML:*
   Odpowiedź AI: Przy ograniczonej liczbie przykładów warto zacząć od cech statystycznych (perplexity, burstiness, stylometria). ML/transformers mają potencjał wyższej dokładności, ale potrzebują większego, zróżnicowanego zbioru. Sensowna jest ścieżka hybrydowa: najpierw baseline statystyczny, potem klasyfikator ML.

2. *Podobieństwo tematyczne tekstów:*

   Odpowiedź AI: Homogeniczność tematyczna pomaga modelom ML (mniej zmiennych zakłócających). Metody statystyczne są bardziej odporne na zmianę domeny, ale i tak warto kontrolować źródło tekstów. Pełna niezależność od tematu jest trudna do osiągnięcia.

3. *Problem krótkich tekstów:*

   Odpowiedź AI: Dla 2-3 zdań należy unikać metryk wymagających stabilnego oszacowania rozkładu tokenów. Lepiej agregować cechy na poziomie dokumentu o ustalonej minimalnej długości albo stosować modele specjalnie do krótkich sekwencji. Alternatywnie - klasyfikować dłuższe fragmenty (akapity).

4. *Minimalny limit długości:*

   Odpowiedź AI: Tak, warto wprowadzić próg (np. liczba słów/tokenów), zwłaszcza przy metrykach statystycznych. Dla ML próg też pomaga, ale model może działać na krótszych próbkach kosztem pewności. Limit powinien wynikać z eksperymentów na wybranym zbiorze.

2.6 Porównanie odpowiedzi eksperta i AI

Pytanie	**dr hab. Piotr Hońko**	**Sztuczna inteligencja**
Statystyka vs ML	Brak jednego lepszego rozwiązania; przy małych danych statystyka może być lepsza.	Zacząć od baseline'u statystycznego; ML przy większych danych; możliwa hybryda.
Podobieństwo tematyczne	Dla statystyki nie jest konieczne; dla ML tak.	Homogeniczność pomaga ML; statystyka odporniejsza na domenę; pełna niezależność trudna.
Krótkie teksty	Dobrać odpowiednie podejście do problemu.	Unikać metryk niestabilnych na krótkich próbkach; agregować dłuższe fragmenty.
Limit długości	Zależy od wybranego podejścia (statystyka / ML).	Warto wprowadzić próg; dla statystyki szczególnie; próg ustalić eksperymentalnie.

Tabela 1: Porównanie konsultacji eksperckiej i AI

Wnioski z konsultacji: przy niepewności co do wielkości zbioru i realnej wykonalności zadania rozsądne jest rozpoczęcie od metod prostszych (statystycznych), z możliwością przejścia do ML, oraz świadome ograniczenie zakresu (m.in. długość tekstu).

3 Skrótowa analiza wymagań

Cel projektu: opracowanie metody (lub zestawu metod) pozwalającej odróżnić tekst napisany przez człowieka od tekstu wygenerowanego przez AI.

ID	Wymaganie	Priorytet
W1	Klasyfikacja binarna: tekst ludzki / tekst AI	wysoki
W2	Minimalna dokładność klasyfikacji $\geq 51\%$ na wybranym zbiorze testowym	wysoki
W3	Obsługa tekstów o ustalonej minimalnej długości (do ustalenia eksperymentalnie)	średni
W4	Porównanie co najmniej jednego podejścia statystycznego i jednego ML (o ile pozwolą dane)	średni
W5	Wykorzystanie otwartego zbioru danych (lub własnego podzbioru)	wysoki
W6	Udokumentowanie ograniczeń metody (krótkie teksty, domena, język)	średni

Tabela 2: Skrótowa lista wymagań

Poprzeczka dokładności została świadomie ustawiona nisko ($51\%+$), ponieważ na etapie planowania nie jest pewne, czy stabilna detekcja jest możliwa przy dostępnych zasobach i danych - zwłaszcza dla języka polskiego.

4 Zakres projektu i harmonogram

4.1 Zakres

W zakresie projektu:

- przegląd metod detekcji tekstu AI,
- wybór i przygotowanie zbioru danych,
- implementacja baseline'u (cechy statystyczne) oraz ewentualnie prostego modelu ML,
- ewaluacja (dokładność, precyzja/czułość w podstawowym zakresie),
- dokumentacja wyników i ograniczeń.

Poza zakresem:

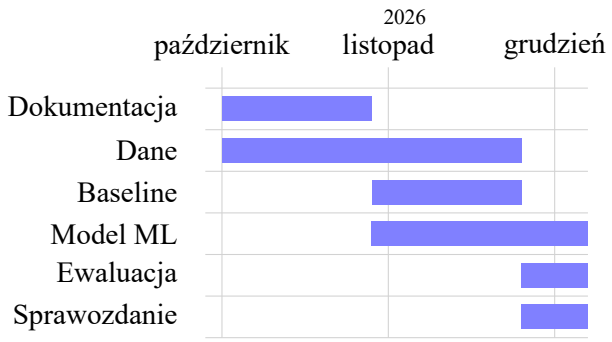
- detekcja w czasie rzeczywistym w produkcie komercyjnym,
- watermarking po stronie generatora,
- pełna odporność na parafrazę i ataki adversarialne,
- gwarancja działania dla dowolnego języka i dowolnego modelu LLM.

4.2 Proponowane zbiory danych

- **LLM Detect AI Generated Text** (Kaggle) - gotowy zbiór do detekcji tekstu AI (https://www.kaggle.com/datasets/sunilthite/llm-detect-ai-generated-
- **SpeakLeash (Spichlerz)** - duży korpus tekstów polskich; źródło tekstów ludzkich do zestawu PL (https://speakleash.org/).
- **HC3 / M4** - zbiory badawcze (głównie EN): human vs ChatGPT / multi-generator.
- **AIDE** - eseje uczniowskie vs LLM (kontekst edukacyjny).

Na starcie planowane jest wykorzystanie zbioru z Kaggle oraz - w miarę możliwości - fragmentów SpeakLeash do eksperymentów z językiem polskim.

4.3 Harmonogram (diagram Gantta)



Rysunek 4.1: Orientacyjny harmonogram prac (październik - grudzień 2026)

5 Szczegółowa specyfikacja projektu i opis wymagań

5.1 Cel i kryterium sukcesu

Sukces projektu definiowany jest jako uzyskanie klasyfikatora (lub metody statystycznej) osiągającego **dokładność co najmniej** 51% na wcześniej odłożonym zbiorze testowym, wraz z opisem warunków, w których wynik jest miarodajny (długość tekstu, język, źródło generatora).

5.2 Wejście / wyjście

- **Wejście:** tekst w formie ciągłej (plik lub łańcuch znaków) spełniający minimalną długość.
- **Wyjście:** etykieta $\{\texttt{human}, \texttt{ai}\}$ oraz - jeśli to możliwe - wynik liczbowy (score / prawdopodobieństwo).

5.3 Założenia

- Prace rozpoczynają się od podejścia statystycznego (zgodnie z konsultacją eksperta przy małej skali danych).
- Dla wariantu ML teksty treningowe powinny być możliwie zbliżone tematycznie (rekomendacja eksperta).
- Limit długości tekstu zostanie ustalony empirycznie.

5.4 Ograniczenia

Dokładność 51% jest progiem minimalnym akceptacji, nie celem optymalnym. Wynik może nie przenosić się na inne domeny, modele LLM ani język polski, jeśli trening odbywał się głównie na danych angielskich.

6 Opis wyników prac

Na obecnym etapie (Zadanie 1) wykonano:

- sformułowanie tematu i wstępnego zakresu projektu,
- przegląd podobnych rozwiązań i stanu wiedzy,
- konsultacje z ekspertem (dr hab. Piotr Hońko) oraz z narzędziem GenAI,
- porównanie obu źródeł rekomendacji,
- skrótową analizę wymagań i wstępny harmonogram,
- wstępną listę zbiorów danych (Kaggle, SpeakLeash i inne).

Implementacja metod detekcji oraz pomiary dokładności będą przedmiotem kolejnych etapów projektu.

7 Oświadczenie wykorzystania narzędzi GenAI

Autorzy oświadczają, że w przygotowaniu niniejszej dokumentacji skorzystano z narzędzi generatywnej AI (m.in. ChatGPT / asystent AI w środowisku Cursor) w zakresie:

- wygenerowania odpowiedzi AI do porównania z konsultacją ekspercką,
- pomocy redakcyjnej przy układzie i sformułowaniu dokumentacji,
- wsparcia przy składzie dokumentu w LaTeX.

Treści merytoryczne dotyczące wymagań, zakresu i interpretacji konsultacji eksperckich zostały zweryfikowane i zaakceptowane przez autorów. Odpowiedzi dr. hab. Piotra Hońko pochodzą z konsultacji przeprowadzonej przez zespół projektowy i nie były generowane automatycznie.

Michał Dąbrowski ..... data .....

Dominik Zabielski ..... data .....

Spis rysunków

4.1 Orientacyjny harmonogram prac (październik - grudzień 2026) 11